



IDÉE D'APPLICATION


SCAN

Code Barre






BILAN APPORTS + RECO





EXPLORATION

_DATASET



2M PRODUITS
183 CATEGORIES

- Origine: Pays Marque...
- Produit: Packaging Catégorie Nom Text Image...
- Composition: Lipides Additifs Huile Palme...
- Scoring: Nutriscore Nitrigrade Nova...
- Suivi: Date Url Id....



NETTOYAGE

_INDICATEURS

183 INDICATEURS


60 Qualitatifs -126 Quantitatifs

64% > 90% de NaN



13 INCATEURS

f(NaN, Redondance, Pertinence)





2M PRODUITS


- Valeurs Abérrantes: 200k
 - > 100 pour 100g et < 0
 - Inclut > Groupe (ex: Sucre dans Glucides)
 - Valeurs Energetiques incohérentes
- Redondants: 202k
- NaN:
 - dropna() sur la Target
 - Remplacement NaN produits par median pnns_groups_2
 - dropna(thresh=11) (2 NàN ou moins)
- Filtre: Produits Français (plus grand nombre de produits)






VARIABLE QUALITATIVES

KEYS VALUES Target











VARIABLE QUALITATIVES

Additifs - Huile Palme






37% sans additifs - 18% en ont 1


+ de 90% sans Huile de Palme






VARIABLE QUANTITATIVES











VARIABLE QUANTITATIVES

BOXPLOTS













RELATION AU NUTRI-GRADE

Pairplot










ANALYSE MULTIVARIÉ

Matrice de corrélation des variables quantitatives



RELATION QUANT-QUANT

Matrice de Corrélation

• Energie:

- 0.6

- 0.4

- 0.2

-0.0

- -0.2


- Lipides
- Acides gras saturés
- Glucides
- Lipides:
 - Acides gras saturés

- Glucides:
 - Sucres





RELATION QUANT-QUAL




	Source	SS	DF	MS	F	p-unc	np2
0	nutriscore_grade	1.486602e+09	4	3.716505e+08	15883.074531	0.0	0.261117
1	Within	4.206630e+09	179777	2.339916e+04	NaN	NaN	NaN



ANALYSE _REDUCTION DE DIMENSION

PCA

Reduction de 7 à 2 dimensions



- F1 (35,6%): Energie et Lipides (+Acides Gras)
- F2 (29,2%): Glucides (+Sucres) Proteines -Sel





KNN

Prévision du Nutri-grade

• Sample: 20000

• Train/Test: 80/20

• Accuracy: **75**%

[[4 [[[140 86 48 11 23	81 316 115 18 7	30	4 11 131 1011 100	3] 3] 15] 66]		64	
			pre	ecisio	n r	recall	f1-score	support
		a b c d e		0.7 0.5 0.6 0.8 0.8	9 8 0	0.79 0.64 0.65 0.82 0.81	0.75 0.61 0.67 0.81 0.84	559 496 886 1233 826
	accu nacro ghted	_		0.7 0.7		0.74 0.75	0.75 0.74 0.75	4000 4000 4000

CONCLUSION FAISABILITÉ

- Dataset: Nombre de produit élévé
- Composition: Accès aux valeurs nutritives
- Classements: Par categories, score, composition...
- Algorithme: Peut compléter les nutri-grade manquants
- Amélioration: Auto-completion des Nan (KNN)



ANNEXESBOUCLE - FONCTION

```
# On supprime tous les produits ayant des valeurs pour 100g > 100 ou < 0
index3_ = ['fat_100g', 'saturated-fat_100g', 'carbohydrates_100g', 'sugars_100g', 'proteins_100g', 'salt_100g']
for i in index3_:
    df_clean = df_clean.drop(df_clean[(df_clean[i] < 0) | (df_clean[i] >= 100)].index)

df_clean3_cols = df_clean3.loc[:,['energy-kcal_100g','fat_100g', 'saturated-fat_100g', 'carbohydrates_100g', 'sugars_100g', 'proteins_100g', 'salt_100g']]
for cols in df_clean3_cols:
    df_clean3[cols].fillna(df_clean3.groupby('pnns_groups_2')[cols].transform('median'), inplace=True)
```



```
for d1, d2 in axis_ranks: # On affiche les 3 premiers plans factoriels, donc les 6 premières composantes
    if d2 < n comp:</pre>
        # initialisation de la figure
        fig, ax = plt.subplots(figsize=(10,10))
        # détermination des limites du graphique
        if lims is not None :
            xmin, xmax, ymin, ymax = lims
        elif pcs.shape[1] < 30 :</pre>
            xmin, xmax, ymin, ymax = -1, 1, -1, 1
        else :
            xmin, xmax, ymin, ymax = min(pcs[d1,:]), max(pcs[d1,:]), min(pcs[d2,:]), max(pcs[d2,:])
        # affichage des flèches
        # s'il y a plus de 30 flèches, on n'affiche pas le triangle à leur extrémité
        if pcs.shape[1] < 30 :</pre>
            plt.quiver(np.zeros(pcs.shape[1]), np.zeros(pcs.shape[1]),
               pcs[d1,:], pcs[d2,:],
               angles='xy', scale units='xy', scale=1, color="grey")
            # (voir la doc : https://matplotlib.org/api/_as_gen/matplotlib.pyplot.quiver.html)
        else:
            lines = [[[0,0],[x,y]] for x,y in pcs[[d1,d2]].T]
            ax.add collection(LineCollection(lines, axes=ax, alpha=.1, color='black'))
        # affichage des noms des variables
        if labels is not None:
            for i,(x, y) in enumerate(pcs[[d1,d2]].T):
                if x \ge x \min \text{ and } x \le x \max \text{ and } y \ge y \min \text{ and } y \le y \max :
                  plt.text(x, y, labels[i], fontsize='14', ha='center', va='center', rotation=label rotation, color="blue", alpha=0.5)
        # affichage du cercle
        an = np.linspace(0, 2 * np.pi, 100) # Add a unit circle for scale
        plt.plot(np.cos(an), np.sin(an))
        plt.axis('equal')
        # définition des limites du graphique
        plt.xlim(xmin, xmax)
        plt.ylim(ymin, ymax)
        # affichage des lignes horizontales et verticales
        plt.plot([-1, 1], [0, 0], color='grey', ls='--')
        plt.plot([0, 0], [-1, 1], color='grey', ls='--')
        # nom des axes, avec le pourcentage d'inertie expliqué
```

def display circles(pcs, n comp, pca, axis ranks, labels=None, label rotation=0, lims=None):


ANNEXES _COMMANDES UTILISÉES

- df = pd.read_csv() # importation de fichier csv
- df.columns # nom colonnes
- **df.dtypes** # types données
- df.shape # taille
- **df.sort_values()** # trie par ordre
- df.isna().mean() # taux valeurs manquantes
- sns.heatmap / sns.histplot() # graphiques sns
- **df.boxplot()** # graphique python

- **df.isin()** # présence élt dans dataframe (boolean)
- **df.drop() / df.dropna()** # Supprime () / Supprimer Na ()
- df.interpolate() # méthode pour remplir NaN
- **df.describe()** # statistiques dataframes
- **df.head** # affiche 15 premières lignes
- **df[df[]>x]** # mask de sélection
- df.loc[] # sélection []
- **df.duplicates()** # identification des duplicatas



ANNEXES _NETTOYAGE



nutriscore_score 0.000000

nutriscore_grade 0.000000 pnns_groups_1 0.000000 fat_100g 0.000002 proteins_100g 0.000002 sugars_100g 0.000015 0.000039 salt_100g saturated-fat_100g 0.000048 carbohydrates_100g 0.000325 countries_en 0.001096 energy-kcal_100g 0.060155 additives_n 0.289007 ingredients_from_palm_oil_n 0.289007 dtype: float64

Après nettoyage



ANNEXES

_INDICATEURS: STATISTIQUES

	additives_n	ingredients_from_palm_oil_n	nutriscore_score	energy-kcal_100g	fat_100g	saturated-fat_100g	carbohydrates_100g	sugars_100g	proteins_100g	salt_100g
count	118002.000000	118002.000000	195743.000000	179782.000000	195742.000000	195742.000000	195682.000000	195742.000000	195743.000000	195740.000000
mean	1.845096	0.050347	9.464405	269.672612	13.948252	5.410349	25.541238	12.883045	8.634954	1.051574
std	2.469573	0.221624	8.786371	177.953920	15.843627	7.700983	25.912209	18.308370	8.630960	2.309968
min	0.000000	0.000000	-15.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.000000	0.000000	2.000000	119.000000	1.500000	0.300000	3.100000	0.800000	2.100000	0.100000
50%	1.000000	0.000000	10.000000	248.000000	8.555000	2.200000	14.000000	3.500000	6.400000	0.610000
75%	3.000000	0.000000	16.000000	392.000000	22.000000	7.800000	49.000000	18.200000	12.300000	1.300000
max	30.000000	2.000000	40.000000	999.000000	99.990000	99.300000	99.950000	99.950000	99.000000	99.000000

